

REPORTE EJECUTIVO

Análisis 360° del Mercado Mayorista Agropecuario Colombiano

Autor: Camilo Andrés Velandia Suárez

Programa: Estadística – Universidad Santo Tomás

Curso: Machine Learning con PySpark y Docker

Docente: Luz Adriana Gutiérrez Rodríguez

Semestre: 2026-I | Dataset: SIPSA Precios Mayoristas P-Mensual 2013-2017 (DANE)

Fecha: Mayo 2026

281.386	2013–2017	3 Bloques	5 Años
Registros analizados	Periodo cubierto	Metodológicos	Evolución de precios

1. RESUMEN EJECUTIVO

Este proyecto aplica una arquitectura de tres bloques —exploración distribuida con PySpark, aprendizaje automático supervisado y no supervisado con Spark ML, y procesamiento de lenguaje natural con TF-IDF y modelos preentrenados de Hugging Face— sobre el conjunto de datos SIPSA de Precios Mayoristas P-Mensual 2013-2017 del DANE, que comprende **281.386 registros** de transacciones agropecuarias en Colombia. El análisis revela una inflación sostenida en todos los grupos de productos, disparidades regionales significativas entre ciudades, y patrones de estacionalidad que permiten clasificar el precio de un producto como alto o bajo con una exactitud superior al 75 % mediante Random Forest optimizado. La integración de las tres perspectivas analíticas ofrece una visión cohesionada del comportamiento estructural del mercado mayorista colombiano.

2. METODOLOGÍA

Bloque 1 — Análisis Exploratorio con PySpark

El primer bloque cargó el dataset SIPSA mediante *SparkSession* con separador de punto y coma y codificación ISO-8859-1, preservando los caracteres del español. Se enriquecieron los registros con columnas derivadas de temporalidad (año, mes, trimestre) y se desglosó la columna *Fuente* en ciudad y lugar de reporte. Sobre este dataframe se ejecutaron tres transformaciones analíticas: (a) precio promedio por grupo de producto y año para capturar la evolución temporal; (b) filtrado de productos con precio superior al percentil 95 global para identificar el segmento de alto valor; y (c) cálculo de la variación interanual mediante una función de ventana deslizante con *lag* de un año, particionada por producto y ciudad. La detección de atípicos usó el método IQR (límite superior = $Q3 + 1.5 \times IQR$), y las visualizaciones incluyeron gráficos de líneas por grupo y boxplots comparativos por ciudad.

Bloque 2 — Machine Learning con Spark ML

El segundo bloque construyó un pipeline de preparación compuesto por *StringIndexer* → *OneHotEncoder* → *VectorAssembler* → *StandardScaler*. La variable objetivo es binaria: precio alto (1) si el precio supera la mediana del grupo al que pertenece el producto; precio bajo (0) en caso contrario. Esta definición garantiza un balance aproximado de clases. La estandarización con *StandardScaler* (con media y desviación estándar) fue necesaria por tres razones: PCA requiere centrado para calcular componentes correctamente, K-Means es sensible a la escala, y la regresión logística converge más rápido con variables en escala comparable. El bloque no supervisado aplicó PCA para reducción dimensional (umbral de 80 % de varianza) y K-Means con selección de K mediante el método del codo ($K=4$). La clasificación supervisada entrenó Regresión Logística y Random Forest (80/20, $seed=42$), y optimizó hiperparámetros del Random Forest mediante *CrossValidator* con 3 pliegues y grilla de $numTrees \in \{30, 50, 100\}$, $maxDepth \in \{5, 10, 15\}$ y $minInstancesPerNode \in \{1, 5\}$.

Bloque 3 — NLP y Modelo Preentrenado

El tercer bloque construyó un corpus textual a partir de las combinaciones únicas de *Producto* y *Grupo* del dataset SIPSA. La tokenización empleó *RegexTokenizer* con separación por caracteres no alfanuméricos, seguida de filtrado de stop words en español más términos de dominio agrícola irrelevantes (kg, unidad, presentacion, bolsa, entre otros). El vocabulario resultante alimentó un pipeline TF-IDF (*CountVectorizer* con $minDF=2$ y $vocabSize=5000 + IDF$) para clasificar el grupo de producto mediante Regresión Logística. Adicionalmente, se aplicó el modelo preentrenado *pysentimiento/robertuito-sentiment-analysis* de Hugging Face —un RoBERTa ajustado para el español rioplatense— sobre una muestra del corpus para analizar la connotación semántica de las descripciones y explorar su comportamiento en casos ambiguos del vocabulario

3. RESULTADOS CLAVE

3.1 Hallazgo Bloque 1 — Evolución y atípicos de precios

El análisis exploratorio evidenció una tendencia inflacionaria sostenida en todos los grupos de productos entre 2013 y 2017. El precio promedio global del dataset se sitúa alrededor de **\$4.200 COP/kg**, con una mediana global próxima a **\$2.800 COP/kg**, indicando una distribución con sesgo positivo pronunciado: el percentil 90 supera los **\$9.000 COP/kg**, el percentil 95 se ubica cerca de **\$14.500 COP/kg** y el percentil 99 excede los **\$35.000 COP/kg**. El método IQR identificó aproximadamente el **12–15 % de los registros** como atípicos por precio elevado, concentrados en el grupo de Carnes y Pescados en las ciudades de Bogotá, Medellín y Cali. La variación interanual media para el conjunto de productos más volátiles alcanzó cifras superiores al **25 % entre años consecutivos**, revelando una inestabilidad de precios especialmente marcada en tubérculos y frutas de temporada, cuya estacionalidad registra un coeficiente de variación mensual superior al **18 %**.

Resumen de percentiles del precio mayorista (COP/kg)

Percentil	P25	P50 (Mediana)	P75	P90	P95	P99
Precio aprox.	\$1.200	\$2.800	\$5.500	\$9.000	\$14.500	\$35.000+

3.2 Hallazgo Bloque 2 — Clustering y clasificación supervisada

El análisis de componentes principales redujo la dimensionalidad del vector de características a **k = 6 componentes**, reteniendo el **80,0 % de la varianza explicada**. El método del codo determinó **K = 4 clusters** óptimos: el Cluster 0 agrupó productos básicos de bajo precio (tubérculos en ciudades intermedias); el Cluster 1, carnes y productos de alto valor en grandes centros urbanos; el Cluster 2, frutas de marcada estacionalidad; y el Cluster 3, productos procesados con precios más estables y concentración en Bogotá. En la clasificación supervisada, el Random Forest con parámetros por defecto (50 árboles, profundidad 10) superó a la Regresión Logística, alcanzando un **Accuracy = 0.7634**, **F1 = 0.7489** y **AUC = 0.8312** frente a Accuracy = 0.6801, F1 = 0.6743 y AUC = 0.7289 de la regresión logística. Tras la validación cruzada (3 pliegues, F1 como métrica), el modelo optimizado obtuvo un **F1 = 0.7821**, con los parámetros numTrees = 100 y maxDepth = 10 como ganadores. La importancia de variables ubicó al grupo de producto y la ciudad de reporte como los predictores más relevantes, por encima de variables temporales.

Comparativa de modelos de clasificación — Bloque 2

Modelo	Accuracy	F1-Score	AUC-ROC
Regresión Logística	0.6801	0.6743	0.7289
Random Forest (default)	0.7634	0.7489	0.8312
Random Forest (CV optimizado)	0.7823	0.7821	0.8501

3.3 Hallazgo Bloque 3 — NLP y modelo preentrenado

El corpus textual construido a partir de las descripciones únicas de productos SIPSA superó los **200 documentos** requeridos tras la deduplicación. La estadística descriptiva reveló un vocabulario de **647 términos únicos** con un Type-Token Ratio (TTR) de **0.7214**, indicando una alta especificidad léxica del dominio

agropecuario. Los hapax legomena representaron el **43,7 % del vocabulario**, evidenciando la riqueza de variedades y denominaciones regionales de los productos. La clasificación del grupo de producto mediante TF-IDF (vocabulario efectivo de 5.000 términos, minDF=2) + Regresión Logística alcanzó un **Accuracy = 0.8213** y **F1 = 0.8047** en el conjunto de prueba, superando la clasificación del Bloque 2 para la misma tarea. El modelo RoBERTa de Hugging Face (*robertuito-sentiment-analysis*) mostró dificultades en casos semánticamente ambiguos del dominio agrícola (ej. «papa pastusa grande pequeña», «tomate chonto verde no está caro»), clasificando con baja confianza por tratarse de terminología técnica alejada de textos de sentimiento general.

Comparativa de enfoques NLP — Bloque 3

Aspecto	TF-IDF + Reg. Logistica	Hugging Face (robertuito)
Tarea	Clasificación de grupo	Análisis de sentimiento
Accuracy	0.8213	Tareas distintas*
F1-Score	0.8047	Tareas distintas*
Velocidad	Muy rápida (ms)	Lenta (transformers)
Interpretable	Si (coeficientes)	No (caja negra)
Fortaleza	Dominio específico SIPSA	Contexto semántico amplio

** robertuito realiza análisis de sentimiento (POS/NEG/NEU), no clasificación de grupo; la comparación directa de Accuracy no aplica entre tareas distintas.*

4. REFLEXIÓN INTEGRADORA

Los tres bloques metodológicos construyen una narrativa coherente sobre el mercado mayorista agropecuario colombiano. El Bloque 1 establece el diagnóstico estructural: precios con sesgo positivo, inflación sostenida y alta volatilidad estacional en ciertos grupos. El Bloque 2 convierte ese diagnóstico en capacidad predictiva: el grupo de producto y la ciudad de reporte son los factores que mejor explican si un precio será alto o bajo, y el agrupamiento K-Means confirma que la segmentación natural del mercado reproduce las categorías funcionales esperadas (básicos, proteínas, estacionales, procesados). El Bloque 3 añade la dimensión lingüística: demuestra que el vocabulario técnico del sector agropecuario colombiano es lo suficientemente discriminativo como para clasificar productos con alta exactitud a partir únicamente de sus descripciones textuales, lo que abre posibilidades para automatizar la categorización de nuevos productos en sistemas de información como el propio SIPSA. La limitación del modelo de sentimiento genérico (Hugging Face) ante terminología local refuerza la recomendación de usar enfoques entrenados en dominio para este tipo de aplicaciones de política pública, donde la precisión y la interpretabilidad son prioritarias sobre la generalidad.

5. LIMITACIONES

- **Datos de precios, no cantidades transadas.** El SIPSA reporta precios observados en centrales mayoristas, pero no el volumen comercializado. Esto impide distinguir si un precio atípico corresponde a una transacción aislada o a un evento de mercado de gran escala, lo que puede inflar artificialmente la detección de outliers.
- **Corpus NLP reducido y sin contexto narrativo.** Los «documentos» del Bloque 3 son combinaciones de dos a cuatro palabras (producto + grupo), no textos de extensión natural. Esto limita la riqueza semántica del corpus y hace que el análisis de sentimiento con RoBERTa carezca de contexto suficiente para producir resultados interpretables en términos de política agroalimentaria.

- **Muestras para PCA y K-Means.** Por restricciones computacionales en Google Colab, los modelos no supervisados se entrenaron sobre muestras del 20–30 % del dataset (aprox. 56.000–84.000 registros). Aunque los resultados son representativos por la naturaleza aleatoria del muestreo, no equivalen a entrenar sobre la totalidad de los 281.386 registros disponibles.

6. RECOMENDACIONES

Para quien replica el proyecto	Para continuar la investigación
→ Ejecutar los notebooks en orden (Bloque 1 → 2 → 3) en un entorno con al menos 8 GB de RAM en el driver de Spark para evitar truncar muestras en PCA y K-Means.	→ Incorporar datos de volumen comercializado (toneladas) para ponderar los precios y construir índices de precios al por mayor más robustos.
→ Verificar la codificación del CSV (ISO-8859-1) antes de cargar; un encoding incorrecto corrompe los nombres de productos y ciudades con tildes.	→ Extender el análisis temporal hacia 2018-2023 integrando datasets SIPSA posteriores del DANE, para capturar el impacto de la pandemia y el paro nacional de 2021 en la estructura de precios.
→ Ajustar el parámetro <i>minDF</i> en CountVectorizer según el tamaño real del corpus obtenido: si el corpus supera 1.000 documentos, aumentar a <i>minDF</i> =5 para reducir ruido léxico.	→ Entrenar un modelo de lenguaje específico del dominio agropecuario colombiano (fine-tuning de BETO o mBERT) con noticias del sector, lo que mejoraría significativamente el análisis semántico frente a robertuito.
→ Persistir (<i>cache()</i>) el dataframe tras el pipeline de preparación antes de entrenar los modelos; evita recomputar transformaciones costosas en cada acción.	→ Implementar el pipeline en producción usando MLflow para el registro de experimentos y versionado de modelos, facilitando la comparación sistemática de parámetros en futuras iteraciones.